深度学习实战教程(一)：感知器

2018年10月25日 12:18:09 14 8,763 °C 编辑

深度学习是啥

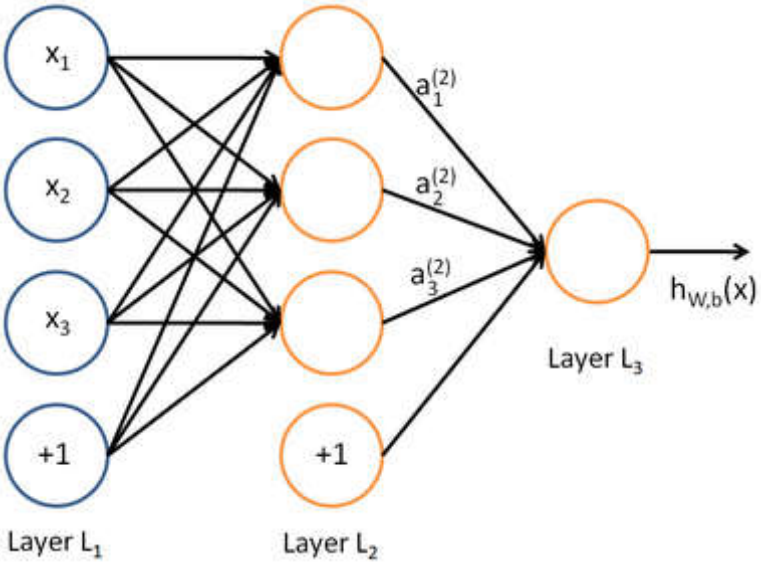

上图中每个圆圈都是一个神经元，每条线表示神经元之间的连接。我们可以看到，上面的神经元被分成了多层，层与层之间的神经元有连接，而层内之间的神经元没有连接。最左边的层叫做**输入层**，这层负责接收输入数据；最右边的层叫**输出层**，我们可以从这层获取神经网络输出数据。输入层和输出层之间的层叫做**隐藏层**。

隐藏层比较多（大于2）的神经网络叫做深度神经网络。而深度学习，就是使用深层架构（比如，深度神经网络）的机器学习方法。

那么深层网络和浅层网络相比有什么优势呢？简单来说深层网络能够表达力更强。事实上，一个仅有一个隐藏层的神经网络就能拟合任何一个函数，但是它需要很多很多的神经元。而深层网络用少得多的神经元就能拟合同样的函数。也就是为了拟合一个函数，要么使用一个浅而宽的网络，要么使用一个深而窄的网络。而后者往往更节约资源。

深层网络也有劣势，就是它不太容易训练。简单的说，你需要大量的数据，很多的技巧才能训练好一个深层网络。这是个手艺活。

感知器

看到这里，如果你还是一头雾水，那也是很正常的。为了理解神经网络，我们应该先理解神经网络的组成单元——**神经元**。神经元也叫做**感知器**。感知器算法在上个世纪50-70年代很流行，也成功解决了很多问题。并且，感知器算法也是非常简单的。

感知器的定义

下图是一个感知器：

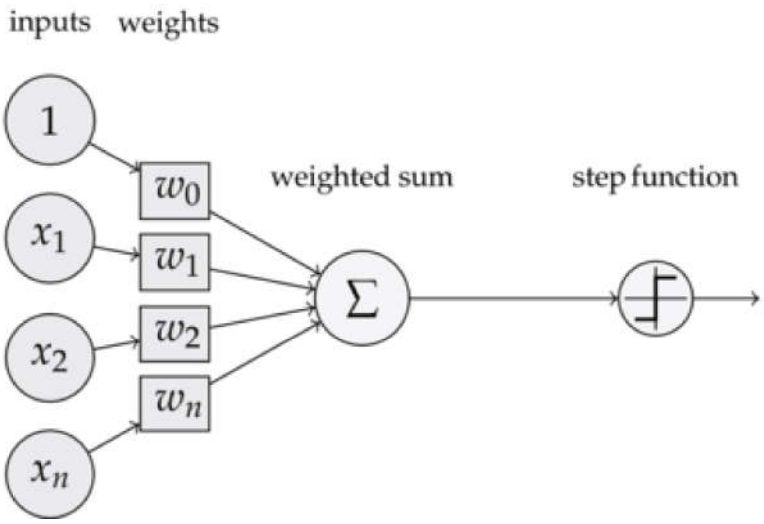

可以看到，一个感知器有如下组成部分：

(1) **输入权值** 一个感知器可以接收多个输入：

$$(x_1, x_2, \ldots, x_n \mid x_i \in \Re)$$

每个输入上有一个**权值**：

$$w_i \in \Re$$

此外还有一个**偏置项**：

$$b \in \Re$$

就是上图中的w0。

(2) **激活函数** 感知器的激活函数可以有很多选择，比如我们可以选择下面这个**阶跃函数f**来作为激活函数：

$$f(z) = \begin{cases} 1 & z > 0 \\ 0 & otherwise \end{cases} \tag{1}$$

(3) **输出** 感知器的输出由下面这个公式来计算：

$$y = f(\mathrm{w} \bullet \mathrm{x} + b) \qquad 公式(1)$$

如果看完上面的公式一下子就晕了，不要紧，我们用一个简单的例子来帮助理解。

例子：用感知器实现and函数

我们设计一个感知器，让它来实现**and**运算。程序员都知道，**and**是一个二元函数（带有两个参数x1和x2），下面是它的**真值表**：

x_1	x_2	y
0	0	0
0	1	0
1	0	0
1	1	1

为了计算方便，我们用0表示**false**，用1表示**true**。这没什么难理解的，对于C语言程序员来说，这是天经地义的。

我们令：

$$w_1 = 0.5; w_2 = 0.5; b = -0.8$$

而激活函数就f是前面写出来的**阶跃函数**，这时，感知器就相当于**and**函数。不明白？我们验算一下：

输入上面真值表的第一行，即x1=0；x2=0，那么根据公式(1)，计算输出：

$$\begin{aligned} y &= f(\mathrm{w} \bullet \mathrm{x} + b) && (2) \\ &= f(w_1 x_1 + w_2 x_2 + b) && (3) \\ &= f(0.5 \times 0 + 0.5 \times 0 - 0.8) && (4) \\ &= f(-0.8) && (5) \\ &= 0 && (6) \end{aligned}$$

也就是当x1x2都为0的时候，y为0，这就是**真值表**的第一行。读者可以自行验证上述真值表的第二、三、四行。

例子：用感知器实现or函数

同样，我们也可以用感知器来实现**or**运算。仅仅需要把偏置项的值设置为-0.3就可以了。我们验算一下，下面是**or**运算的**真值表**：

x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	1

我们来验算第二行，这时的输入是x1=0；x2=1，带入公式(1)：

$$
\begin{aligned}
y &= f(\mathrm{w} \bullet \mathrm{x} + b) && (7)\\
&= f(w_1 x_1 + w_2 x_2 + b) && (8)\\
&= f(0.5 \times 1 + 0.5 \times 0 - 0.3) && (9)\\
&= f(0.2) && (10)\\
&= 1 && (11)
\end{aligned}
$$

也就是当x1=0；x2=1时，y为1，即**or真值表**第二行。读者可以自行验证其它行。

感知器还能做什么

事实上，感知器不仅仅能实现简单的布尔运算。它可以拟合任何的线性函数，任何**线性分类**或**线性回归**问题都可以用感知器来解决。前面的布尔运算可以看作是**二分类**问题，即给定一个输入，输出0（属于分类0）或1（属于分类1）。如下面所示，**and**运算是一个线性分类问题，即可以用一条直线把分类0（false，红叉表示）和分类1（true，绿点表示）分开。

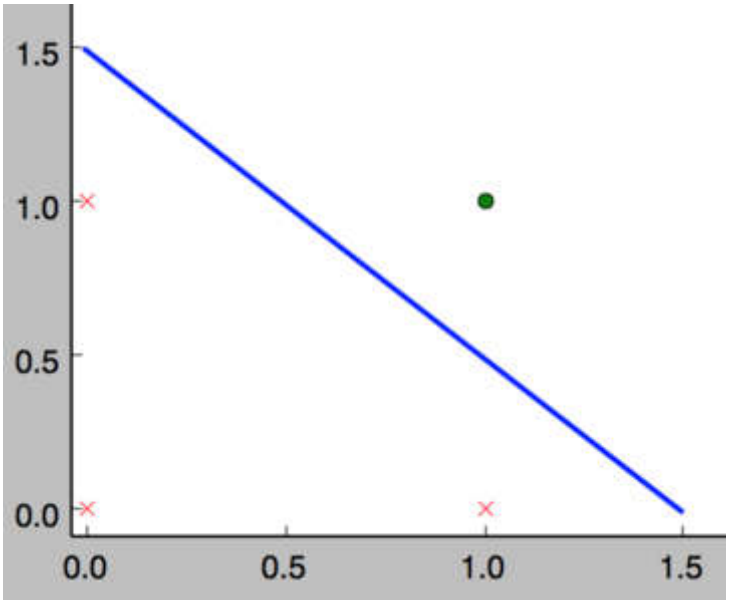

然而，感知器却不能实现异或运算，如下图所示，异或运算不是线性的，你无法用一条直线把分类0和分类1分开。

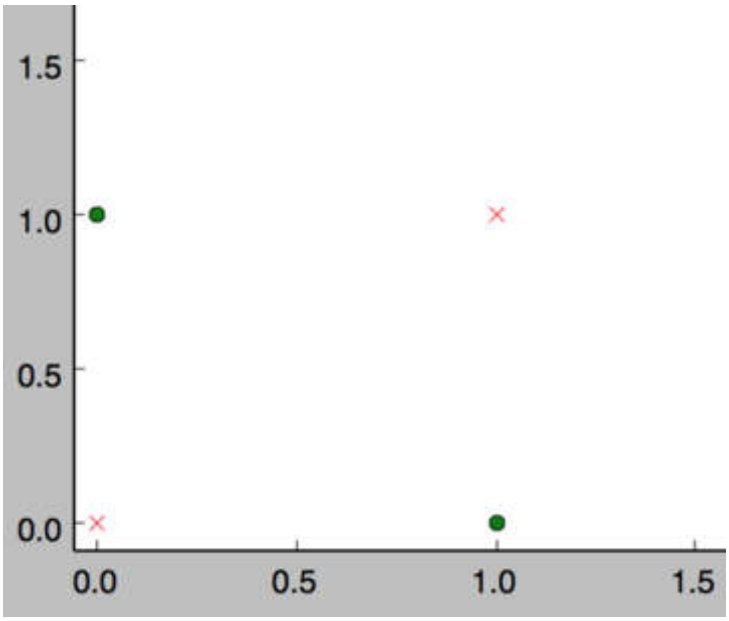

感知器的训练

现在，你可能困惑前面的权重项和偏置项的值是如何获得的呢？这就要用到感知器训练算法：将权重项和偏置项初始化为0，然后，利用下面的**感知器规则**迭代的修改wi和b，直到训练完成。

$$w_i \leftarrow w_i + \Delta w_i \tag{12}$$
$$b \leftarrow b + \Delta b \tag{13}$$

其中:

$$\Delta w_i = \eta(t-y)x_i \tag{14}$$
$$\Delta b = \eta(t-y) \tag{15}$$

wi是与输入xi对应的权重项，b是偏置项。事实上，可以把b看作是值永远为1的输入xb所对应的权重。t是训练样本的**实际值**，一般称之为**label**。而y是感知器的输出值，它是根据**公式(1)**计算得出。η是一个称为**学习速率**的常数，其作用是控制每一步调整权的幅度。

每次从训练数据中取出一个样本的输入向量x，使用感知器计算其输出y，再根据上面的规则来调整权重。每处理一个样本就调整一次权重。经过多轮迭代后（即全部的训练数据被反复处理多轮），就可以训练出感知器的权重，使之实现目标函数。

编程实战：实现感知器

完整代码请参考GitHub：点击查看

对于程序员来说，没有什么比亲自动手实现学得更快了，而且，很多时候一行代码抵得上千言万语。接下来我们就将实现一个感知器。

下面是一些说明：

- 使用python语言。python在机器学习领域用的很广泛，而且，写python程序真的很轻松。
- 面向对象编程。面向对象是特别好的管理复杂度的工具，应对复杂问题时，用面向对象设计方法很容易将复杂问题拆解为多个简单问题，从而解救我们的大脑。
- 没有使用numpy。numpy实现了很多基础算法，对于实现机器学习算法来说是个必备的工具。但为了降低读者理解的难度，下面的代码只用到了基本的python（省去您去学习numpy的时间）。

下面是感知器类的实现，非常简单。去掉注释只有27行，而且还包括为了美观（每行不超过60个字符）而增加的很多换行。

Python

```
1  from functools import reduce
2
3  class Perceptron():
4      def __init__(self, input_num, activator):
5          '''
6          初始化感知器，设置输入参数的个数，以及激活函数。
7          激活函数的类型为double -> double
8          '''
9          self.activator = activator
10         # 权重向量初始化为0
11         self.weights = [0.0 for _ in range(input_num)]
12         # 偏置项初始化为0
13         self.bias = 0.0
14     def __str__(self):
15         '''
16         打印学习到的权重、偏置项
17         '''
18         return 'weights\t:%s\nbias\t:%f\n' % (self.weights, self.bias)
19     def predict(self, input_vec):
20         '''
21         输入向量，输出感知器的计算结果
22         '''
```

```
        # 把input_vec[x1,x2,x3...]和weights[w1,w2,w3,...]打包在一起
        # 变成[(x1,w1),(x2,w2),(x3,w3),...]
        # 然后利用map函数计算[x1*w1, x2*w2, x3*w3]
        # 最后利用reduce求和
        return self.activator(
            reduce(lambda a, b: a + b,list(map(lambda x, w: x * w, input_vec, self.weights)), 0
    def train(self, input_vecs, labels, iteration, rate):
        '''
        输入训练数据：一组向量、与每个向量对应的label；以及训练轮数、学习率
        '''
        for i in range(iteration):
            self._one_iteration(input_vecs, labels, rate)
    def _one_iteration(self, input_vecs, labels, rate):
        '''
        一次迭代，把所有的训练数据过一遍
        '''
        # 把输入和输出打包在一起，成为样本的列表[(input_vec, label), ...]
        # 而每个训练样本是(input_vec, label)
        samples = zip(input_vecs, labels)
        # 对每个样本，按照感知器规则更新权重
        for (input_vec, label) in samples:
            # 计算感知器在当前权重下的输出
            output = self.predict(input_vec)
            # 更新权重
            self._update_weights(input_vec, output, label, rate)
    def _update_weights(self, input_vec, output, label, rate):
        '''
        按照感知器规则更新权重
        '''
        # 把input_vec[x1,x2,x3,...]和weights[w1,w2,w3,...]打包在一起
        # 变成[(x1,w1),(x2,w2),(x3,w3),...]
        # 然后利用感知器规则更新权重
        delta = label - output
        self.weights = list(map(lambda x, w: w + rate * delta * x, input_vec, self.weights))
        # 更新bias
        self.bias += rate * delta
```

接下来，我们利用这个感知器类去实现**and**函数。

Python

```
def f(x):
    '''
    定义激活函数f
    '''
    return 1 if x > 0 else 0
def get_training_dataset():
    '''
    基于and真值表构建训练数据
    '''
    # 构建训练数据
    # 输入向量列表
    input_vecs = [[1,1], [0,0], [1,0], [0,1]]
    # 期望的输出列表，注意要与输入一一对应
    # [1,1] -> 1, [0,0] -> 0, [1,0] -> 0, [0,1] -> 0
    labels = [1, 0, 0, 0]
    return input_vecs, labels
def train_and_perceptron():
    '''
    使用and真值表训练感知器
    '''
    # 创建感知器，输入参数个数为2（因为and是二元函数），激活函数为f
    p = Perceptron(2, f)
    # 训练，迭代10轮，学习速率为0.1
    input_vecs, labels = get_training_dataset()
    p.train(input_vecs, labels, 10, 0.1)
    #返回训练好的感知器
    return p
if __name__ == '__main__':
```

```
    # 训练and感知器
    and_perception = train_and_perceptron()
    # 打印训练获得的权重
    print(and_perception)
    # 测试
    print('1 and 1 = %d' % and_perception.predict([1, 1]))
    print('0 and 0 = %d' % and_perception.predict([0, 0]))
    print('1 and 0 = %d' % and_perception.predict([1, 0]))
    print('0 and 1 = %d' % and_perception.predict([0, 1]))
```

将上述程序保存为perceptron.py文件，通过命令行执行这个程序，其运行结果为：

```
weights :[0.1, 0.2]
bias    :-0.200000

1 and 1 = 1
0 and 0 = 0
1 and 0 = 0
0 and 1 = 0
[Finished in 0.2s]
```

神奇吧！感知器竟然完全实现了**and**函数。读者可以尝试一下利用感知器实现其它函数。

小结

终于看（写）到小结了...，大家都累了。对于零基础的你来说，走到这里应该已经很烧脑了吧。没关系，休息一下。值得高兴的是，你终于已经走出了深度学习入门的第一步，这是巨大的进步；坏消息是，这仅仅是最简单的部分，后面还有无数艰难险阻等着你。不过，你学的困难往往意味着别人学的也困难，掌握一门高门槛的技艺，进可糊口退可装逼，是很值得的。

下一篇文章，我们将讨论另外一种感知器：**线性单元**，并由此引出一种可能是最最重要的优化算法：**梯度下降**算法。

参考资料

1. Tom M. Mitchell, "机器学习", 曾华军等译, 机械工业出版社

PS：该文章为转载文，感觉写得很精彩，顾分享给大家，已将原文作者python2的代码改为python3的代码。

原文链接：https://www.zybuluo.com/hanbingtao/note/433855

感谢原作者的付出！

爱所有人，信任少数人，不负任何人。--- 莎士比亚